

AlzoLab

Laboratorio de lingüística de corpus en el navegador, sin escribir código

EN PRODUCCIÓN


Python · Streamlit · spaCy

QUÉ HACE

Convierte un conjunto de textos en un corpus analizable sin escribir una línea de código: importación desde varias fuentes (web, Wikipedia, archivos propios), limpieza y normalización, análisis morfosintáctico con spaCy, extracción automática de términos relevantes (C-value) y concordancias KWIC para ver cada término en su contexto real de uso.

Todo el flujo — desde subir los textos hasta exportar los resultados — ocurre dentro de la misma interfaz, pensado para alguien sin experiencia de programación.

CÓMO SE VE EN USO




The image displays two side-by-side screenshots of the AlzoLab web application interface, illustrating the initial steps of the corpus analysis workflow.

Left Screenshot (Importar): This panel shows the 'Importar' (Import) step, labeled 'Fase 1 de 6'. It includes a navigation bar with tabs: Importar, Limpiar, Analizar, Terminología, Concordancia, and Exportar. The 'Importar' section has a sub-header 'Reúne textos desde varias fuentes. Cada documento se normaliza (NFKC) y los duplicados exactos se descartan automáticamente.' Below this, there are buttons for 'Páginas web', 'Wikipedia', 'Archivos', and 'Proyecto'. A text input field labeled 'URLs (una por línea)' contains the example URL 'https://es.wikipedia.org/wiki/Lingüística_de_corpus'. At the bottom, there is a dropdown menu set to 'Automático (trafilitura)' and an 'Extraer' button. A small note mentions that the interface detects the body of the article for news items using BeautifulSoup.

Right Screenshot (Limpiar): This panel shows the 'Limpiar' (Clean) step, labeled 'Fase 2 de 6'. It includes the same navigation bar. The 'Limpiar' section has a sub-header 'Combina presets o reglas propias. El orden importa y cada regex tiene un límite de ejecución.' Below this, there are several buttons: 'Quitar referencias [12]', 'Quitar URLs', 'Quitar emails', 'Recortar líneas', 'Unir líneas', 'Colapsar saltos', 'Quitar dígitos sueltos', and 'Normalizar espacios'. A text input field labeled '1. Quitar URLs' contains the regex '(?http[s]?://www\..)*\$*[%&.,:;!?]{1}'. Below the input field, there is a 'Normalizar' button and a 'Normalizar espacios' button. A small note mentions that users can write their own regular expressions.

Bottom Section: Below the screenshots, there is a section titled '1. Importación — múltiples fuentes: web, Wikipedia o archivos propios.' and '2. Limpieza — normalización del texto antes del análisis.'



Concordancia KWIC
Localiza una palabra o frase y compara cada uso dentro de su contexto.

Palabra o frase: Ventana: 7 Límite: 100 Buscar

7 concordancias

Documento	Contexto izquierdo	Palabra	Contexto derecho
Ejemplo: L1...	La lingüística de	corpus	es una metodología que estudia la lengua
Ejemplo: L1...	una misma lengua las herramientas modernas combinan	corpus	anotados con técnicas de procesamiento del lenguaje

4. Concordancias — cada término en su contexto real de uso.

SERVICIOS QUE PUEDO OFRECER CON ESTO

- **Extracción de terminología especializada** de un fondo documental (técnico, jurídico, médico) como base para un glosario o una memoria de traducción.
- **Análisis de corpus a medida** para traductores, editoriales o equipos de contenido que trabajan con grandes volúmenes de texto.