

// juan manuel neupavert alzola

AlzoLab

Laboratorio de lingüística de corpus en el navegador, sin escribir código

en producción

FastAPI · React + Vite · spaCy · Docker

// qué hace

Convierte un conjunto de textos en un corpus analizable sin escribir una línea de código: importación desde varias fuentes (web, Wikipedia, archivos propios), limpieza y normalización, análisis morfosintáctico con spaCy, extracción automática de términos relevantes y concordancias KWIC para ver cada término en su contexto real de uso. Funciona en español e inglés — un único selector cambia tanto el idioma de la interfaz como el modelo de spaCy usado en el análisis.

La extracción terminológica usa el algoritmo C-value (Frantzi, Ananiadou y Mima, 2000), un método estadístico-lingüístico estándar en la literatura de extracción terminológica, no una heurística improvisada.

Todo el flujo — desde subir los textos hasta exportar los resultados — ocurre dentro de la misma interfaz, pensado para alguien sin experiencia de programación. El código es abierto (MIT) y está en GitHub, con tests automáticos en cada cambio.

// detalle técnico

La lógica de análisis de corpus vive separada del framework web (backend/app/core), como funciones puras que reciben datos y devuelven estructuras — se pueden probar y reutilizar sin levantar ningún servidor. El contrato entre el frontend (React) y el backend (FastAPI) es JSON tipado con Pydantic, no strings sueltos que hay que re-interpretar.

Todo el pipeline — importación con trafilatura/jusText/BeautifulSoup, limpieza con reglas regex protegidas contra ataques ReDoS, análisis con spaCy, extracción terminológica — corre dentro de un único contenedor Docker, lo que hace que la demo pública y una instancia privada para un cliente sean exactamente el mismo despliegue.


// ejemplo concreto

Una editorial que quiere identificar la terminología propia de una colección de manuales técnicos antes de traducirlos: se importan los documentos, se limpian automáticamente, y la pestaña de Terminología devuelve una lista de candidatos rankeados por relevancia estadística — en minutos, no releendo cientos de páginas a mano para anotar términos.

// cómo empezamos

La demo pública ya está accesible sin instalar nada — es la forma más rápida de ver si encaja con lo que necesitas. Si el corpus tiene que quedar separado del demostrador público (por volumen o por confidencialidad), se despliega una instancia propia con el mismo contenedor Docker.


// cómo se ve en uso




1. Importación — múltiples fuentes: web, Wikipedia o archivos propios.



2. Limpieza — normalización del texto antes del análisis.



3. Análisis — análisis morfosintáctico automático.



4. Concordancias — cada término en su contexto real de uso.

// servicios que puedo ofrecer con esto

- **Extracción de terminología especializada** de un fondo documental (técnico, jurídico, médico) como base para un glosario o una memoria de traducción, en español o en inglés.
- **Análisis de corpus a medida** para traductores, editoriales o equipos de contenido que trabajan con grandes volúmenes de texto — importación desde web, Wikipedia o archivos propios incluida.
- **Puesta en marcha de una instancia propia** si necesitas mantener tu corpus separado del demostrador público.