

// juan manuel neupavert alzoia

AlzoLab

Laboratorio de lingüística de corpus en el navegador: del texto en bruto a términos, concordancias y métricas, sin escribir una línea de código

en producción · demo pública

FastAPI · React + Vite · spaCy (ES/EN) · trafilatura · jusText · Docker · código abierto (MIT)

// el problema

Construir un corpus para investigación lingüística o para un proyecto de NLP suele significar pegar scripts sueltos: uno para descargar páginas web, otro para limpiar el HTML, otro para etiquetar con spaCy, otro para volcar a CSV. Es repetitivo y poco reproducible.

Para quien viene de la lingüística y no quiere montar una infraestructura nueva en cada experimento, esa barrera técnica se come el tiempo que debería ir al análisis.

Y las herramientas consolidadas de lingüística de corpus (Sketch Engine y similares) son potentes pero pesadas, de pago y difíciles de desplegar en una instancia propia sobre un corpus confidencial.

// qué hace

AlzoLab es una **única aplicación web con el flujo completo guiado en pestañas**, disponible en español e inglés — un mismo selector cambia el idioma de la interfaz y el modelo de spaCy usado en el análisis. Convierte un conjunto de textos en un corpus analizable sin escribir código:

1. **Importar** — extrae el contenido de páginas web (artículos y noticias, limpiando menús y anuncios con trafilatura / jusText / BeautifulSoup), de Wikipedia, o de archivos propios (.txt, .pdf, .docx), con normalización de caracteres y deduplicado. Se revisa qué entra en cada corpus antes de añadirlo.
2. **Limpiar** — reglas de expresión regular con **vista previa antes/después en vivo** y una guardia que evita reglas capaces de colgar el sistema.
3. **Analizar** — etiquetado gramatical y morfológico con spaCy: distribución de categorías, lemas frecuentes, n-gramas y métricas léxicas (riqueza de vocabulario, hápax, densidad). El resultado se cachea por corpus.
4. **Terminología** — términos candidatos filtrados por patrón gramatical y rankeados con el algoritmo **C-value** (Frantzi, Ananiadou y Mima, 2000), un método estándar en la literatura de extracción terminológica, no una heurística improvisada.
5. **Concordancia (KWIC)** — busca una palabra o frase y la muestra centrada, con su contexto izquierdo y derecho alineados.
6. **Exportar** — descarga del corpus o del análisis en .txt, .json o .csv.

Todo ocurre dentro de la misma interfaz, pensada para alguien sin experiencia de programación. El código es abierto (licencia MIT), está en GitHub y pasa una batería de pruebas automáticas en cada cambio.

// cómo funciona por dentro

La **lógica de análisis de corpus vive separada del framework web**: son funciones puras que reciben datos y devuelven estructuras, de modo que se pueden probar y reutilizar sin levantar ningún servidor. El contrato entre la interfaz (React) y el backend (FastAPI) es JSON tipado y validado, no cadenas de texto que haya que re-interpretar.

Todo el proceso — importación, limpieza, análisis con spaCy, extracción terminológica — corre dentro de **un único contenedor Docker**. Eso hace que la demo pública y una instancia privada para un cliente sean exactamente el mismo despliegue, sin diferencias de comportamiento.

// un caso concreto

Una editorial que quiere identificar la terminología propia de una colección de manuales técnicos antes de traducirlos. Se importan los documentos, se limpian automáticamente, y la pestaña de Terminología devuelve una lista de candidatos ordenados por relevancia estadística — en minutos, en vez de releer cientos de páginas a mano anotando términos.

A partir de ahí, las concordancias KWIC permiten ver cómo se usa realmente cada término candidato en su contexto, para decidir cuáles entran en el glosario y con qué definición.

// cómo empezamos

La **demo pública** ya está accesible sin instalar nada — es la forma más rápida de ver si encaja con lo que necesitas (se duerme con la inactividad y despierta en la primera visita).

Si el corpus tiene que quedar separado del demostrador público, por volumen o por confidencialidad, se despliega una **instancia propia** con el mismo contenedor Docker, en tu servidor o en uno que yo gestione.

// cómo se ve en uso

Alzolab

corpus · 3 docs · 1141 car. · Cómo funciona · El proyecto · ES · EN

Importar

Limpiar

Analizar

Terminología

Concordancia

Exportar

Importar

Fase 1 de 6

Reúne textos desde varias fuentes. Cada documento se normaliza (NFKC) y los duplicados exactos se descartan automáticamente.

Páginas web

Wikipedia

Archivos

Proyecto

URLs (una por línea)

https://es.wikipedia.org/wiki/Lingüística_de_corpus

https://...

Automático (trafíatura)

Extraer

Cargar ejemplo

Automático detecta el cuerpo del artículo (solo para noticias). JustText y BeautifulSoup son alternativas si el método automático falla.

Corpus en sesión

3 documentos · 1141 caracteres

Vaciar

EJEMPLO

Ejemplo: Lingüística de corpus
La lingüística de corpus es una metodología que estudia la lengua a partir de colecciones extensas de textos reales. En lugar de apoyarse...

402 car.

EJEMPLO

Ejemplo: Etiquetado POS
El etiquetado morfosintáctico, conocido como POS tagging, asigna a cada palabra de un texto su categoría gramatical: sustantivo, verbo...

376 car.

EJEMPLO

Ejemplo: Lematización
La lematización reduce cada forma flexionada a su forma o forma de diccionario. Así, las palabras corremos, corrió y corrieron se agrupan...

331 car.

Alzolab · Juan Manuel Neupaver Alzola · MIT

1. Importar — múltiples fuentes: web, Wikipedia o archivos propios, con revisión previa.

Alzolab

corpus · 3 docs · 1141 car. · Cómo funciona · El proyecto · ES · EN

Importar

Limpiar

Analizar

Terminología

Concordancia

Exportar

Limpiar

Fase 2 de 6

Combina presets o reglas propias. El orden importa y cada regex tiene un límite de ejecución.

Quitar referencias [02]

Quitar URLs

Quitar emails

Recorrer líneas

Unir líneas

Colapsar saltos

Quitar dígitos sueltos

Normalizar espacios

1. Quitar URLs

(?https?://www\.)?de[^\s,;:]{7,}

Reemplazo (vacío = eliminar)

+ Añadir regla manual

Puedes escribir cualquier expresión regular; se aplica de forma segura con un límite de tiempo.

Vista previa antes / después

Ejemplo: Lingüística de corpus



9 REEMPLAZOS · SIN CAMBIOS

La lingüística de corpus es una metodología que estudia la lengua a partir de colecciones extensas de textos reales. En lugar de apoyarse solo en la intuición del investigador, analiza patrones de uso observados en datos auténticos. Permite medir la frecuencia de palabras, describir colocaciones y comparar variedades de una misma lengua. Las herramientas modernas combinan corpus anotados con técnicas de procesamiento del lenguaje natural.

Aplicar al corpus

Alzolab · Juan Manuel Neupaver Alzola · MIT

2. Limpiar — reglas regex con vista previa antes/después.



CAPTURA PENDIENTE

Pestaña de Terminología

La lista de términos candidatos rankeados por C-value, con su puntuación y su frecuencia.

CAPTURA PENDIENTE

Exportación

El diálogo de exportación del corpus o del análisis en txt / json / csv.

// preguntas frecuentes

¿Mis textos se quedan guardados en algún sitio?

La demo pública trabaja sobre datos de sesión y de ejemplo; no es para material confidencial. Para eso se despliega una instancia propia y aislada.

¿En qué idiomas funciona?

Español e inglés, tanto la interfaz como el análisis (cada uno con su modelo de spaCy).

¿Qué es el C-value?

Un método estadístico-lingüístico estándar para puntuar qué secuencias de palabras de un corpus son términos reales y no combinaciones casuales, teniendo en cuenta también los términos anidados dentro de otros más largos.

¿Puedo quedarme el código?

Sí: es abierto, con licencia MIT, en GitHub. El servicio que ofrezco es el despliegue, la puesta a punto sobre tu corpus y el análisis.

// servicios que puedo ofrecer con esto

- **Extracción de terminología especializada** de un fondo documental (técnico, jurídico, médico) como base para un glosario o una memoria de traducción, en español o en inglés.
- **Análisis de corpus a medida** para traductores, editoriales o equipos de contenido que trabajan con grandes volúmenes de texto.
- **Puesta en marcha de una instancia propia** si necesitas mantener tu corpus separado del demostrador público.