

// juan manuel neupavert alzola

NeupaLang (Documentación lingüística)

Plataforma para documentar lenguas minoritarias y en peligro: lexicón, corpus anotado, informantes con consentimiento e interoperabilidad real con FLEx y ELAN

en desarrollo

FastAPI · SQLAlchemy 2 · PostgreSQL (full-text) · React 18 + TypeScript · i18n ES·EN·FR·DE·IT ·
export LIFT / EAF / CLDF

// el problema

De las cerca de 7000 lenguas del mundo, una parte muy grande está en peligro de desaparición. La documentación de campo es la forma de preservarlas — y las herramientas para hacerla son en su mayoría software de escritorio antiguo (FLEx, Toolbox), con una curva de aprendizaje de meses y sin colaboración entre equipos distribuidos.

Los datos, además, suelen quedar atrapados en formatos propietarios: si la herramienta deja de mantenerse, el trabajo de años se vuelve difícil de recuperar.

Y la dimensión ética — el consentimiento de los hablantes, qué usos autorizan, qué material es sensible o sagrado — se suele gestionar aparte, en documentos sueltos, cuando debería ser parte del propio registro.

// qué hace

NeupaLang es una **plataforma web de documentación lingüística** para lingüistas, investigadores y comunidades. Cubre los tres frentes del trabajo de campo en un mismo sitio:

- **Lexicón** — entradas con transcripción fonética (IPA, con teclado asistido y validación), categoría gramatical y variantes ortográficas; cada entrada con varias **acepciones**, y cada acepción con sus **ejemplos** en formato de glosa interlineal. Subíndices automáticos para homónimos. Historial de cambios completo, con posibilidad de volver a una versión anterior.
- **Corpus textual** — narrativas, conversaciones, textos rituales, con metadatos (género, registro, fecha y lugar de grabación, sensibilidad). Cada texto se divide en **líneas anotadas morfema a morfema**, alineables con audio o vídeo por marcas de tiempo, y los lexemas mencionados se vinculan al diccionario.
- **Informantes** — colaboradores registrados con código anónimo y datos demográficos, y sobre todo con **consentimiento informado** estructurado: tipo (oral, escrito, grabado), alcance (solo investigación, publicación, difusión pública), fecha, vigencia y revocación registrada. Si un informante revoca el consentimiento, su material asociado se marca como restringido.

Las **glosas interlineales** siguen las Leipzig Glossing Rules, con más de 60 abreviaturas estándar y un editor que se puede usar en modo texto libre o palabra por palabra. Cada lengua puede definir **campos personalizados** (clase nominal, tono, clasificador, etimología, préstamos...) que aparecen luego en cada entrada.

El trabajo es **colaborativo**, con roles de propietario, editor y solo lectura, glosarios públicos o privados, notificaciones y búsqueda de texto completo multilingüe. La interfaz está disponible en cinco idiomas.

// interoperabilidad: los datos no quedan cautivos

NeupaLang importa y exporta los formatos que ya usan los lingüistas de campo, para que se pueda entrar y salir sin fricción:

- **FLEx / WeSay** (formato LIFT) — importación y exportación completas, con estrategia de fusión configurable (omitir, sobrescribir o combinar duplicados).
- **ELAN** (formato EAF) — importación y exportación, con mapeo de las capas de anotación (referencia, transcripción, traducción).
- **Praat** — exportación a EAF.
- **CLDF** — exportación a Cross-Linguistic Data Formats, el estándar para archivos lingüísticos y catálogos como Glottolog.

Más exportación a JSON (copia de seguridad completa), CSV (hojas de cálculo) y PDF (impresión y publicación). Los códigos de lengua siguen el estándar ISO 639-3.

// gestión ética integrada (care / fair)

El consentimiento y la sensibilidad no son un añadido: forman parte del modelo de datos. Cada nivel — lengua, informante, entrada, texto — lleva sus propios metadatos de sensibilidad y de derechos, siguiendo los principios **CARE** (soberanía de los datos de las comunidades) y **FAIR** (datos localizables, accesibles, interoperables y reutilizables).

En la práctica: un texto puede marcarse como público, restringido o sagrado; un informante puede autorizar solo uso académico y no publicación; y esa distinción se respeta en las exportaciones y en quién puede ver qué.

// estado del proyecto

El lexicón, el corpus y la exportación a los formatos estándar están **funcionales**, con una batería de varios cientos de pruebas automáticas del backend en verde. Está en desarrollo un **editor de escritorio con modo sin conexión**, pensado para el trabajo de campo en zonas sin acceso fiable a internet, que sincroniza al recuperar la conexión.

Es un proyecto de investigación a largo plazo, no un producto cerrado a la venta.

// un caso concreto

Un proyecto de documentación de una lengua indígena con trabajo de campo en una zona sin internet fiable. El investigador registra el lexema, su glosa interlineal y el consentimiento del hablante — incluyendo si autoriza solo uso académico o también publicación — en el dispositivo; los datos se sincronizan cuando vuelve a tener conexión, sin haber dependido de ella durante el trabajo de campo. Al terminar la campaña, exporta a FLEx para seguir en su flujo habitual, o a CLDF para archivar.

// cómo encajaría un proyecto

Si tu equipo de documentación lingüística trabaja con este enfoque, hablamos de qué fase está lista para tu caso concreto antes de comprometer nada: puesta en marcha de una instancia, importación de datos existentes desde FLEx o ELAN, definición de los campos personalizados de la lengua y formación del equipo.

// cómo se ve en uso

CAPTURA PENDIENTE

Ficha de lexema

Una entrada del diccionario con su transcripción IPA, categoría, variantes y sus acepciones desplegadas.

CAPTURA PENDIENTE

Editor de glosa interlineal (IGT)

El editor palabra por palabra con las tres líneas (original, segmentación, glosa Leipzig) y la traducción libre.

CAPTURA PENDIENTE

Ficha de informante con consentimiento

El formulario de consentimiento estructurado: tipo, alcance, fecha, vigencia y el botón de revocación.

CAPTURA PENDIENTE

Corpus: línea anotada

Un texto del corpus con una línea segmentada morfema a morfema y alineada con su marca de tiempo de audio.

CAPTURA PENDIENTE

Importar/exportar

El diálogo de interoperabilidad mostrando FLEx (LIFT), ELAN (EAF) y CLDF con la estrategia de fusión.

// preguntas frecuentes

¿Sustituye a FLEx o a ELAN?

No pretende sustituirlos: se integra con ellos. Se puede empezar un proyecto en NeupaLang y exportarlo a FLEx, o traer datos de ELAN y seguir en la web.

¿Cómo se gestiona el consentimiento de los hablantes?

De forma estructurada dentro del propio registro: tipo, alcance, vigencia y revocación. Una revocación marca el material asociado como restringido y se respeta en las exportaciones.

¿Funciona sin conexión para el trabajo de campo?

La plataforma web necesita conexión. El editor de escritorio con modo sin conexión, pensado para eso, está en desarrollo.

¿Qué formatos de salida hay?

LIFT (FLEx/WeSay), EAF (ELAN, Praat), CLDF, más JSON, CSV y PDF. Códigos de lengua en ISO 639-3.

// para quién es útil

- Equipos de documentación lingüística y proyectos de investigación sobre lenguas minoritarias que necesitan trabajar con datos de campo de forma rigurosa y éticamente responsable, con interoperabilidad real hacia FLEx y ELAN en vez de un formato propio cerrado.
- Puesta en marcha de una instancia, importación de datos existentes y definición de los campos personalizados de cada lengua.