

// juan manuel neupavert alzola

Digitalizador documental (OCR local)

Convierte documentos escaneados en texto buscable y editable — sin conexión a internet

en desarrollo

Python · Transformers · PyMuPDF · 100% local

// qué hace

Recibe un PDF escaneado o una foto y decide, página a página, si ya contiene texto digital o si necesita reconocimiento óptico de caracteres. Tiene dos modos: uno rápido para el uso normal y otro más lento y preciso, pensado para páginas con letra pequeña o mala calidad de escaneo.

Cuando el sistema no puede leer un fragmento con suficiente confianza, lo marca explícitamente como «página ilegible» en vez de rellenarlo con una suposición; si el texto reconocido tiene más palabras raras de lo normal, avisa para que se revise antes de darlo por bueno — una decisión deliberada para no introducir errores silenciosos en un documento que después alguien va a dar por bueno.

El resultado no es solo un texto suelto: junto al PDF original se genera una copia con el escaneo intacto visualmente pero con una capa de texto invisible superpuesta, así que se puede buscar y seleccionar texto en cualquier lector de PDF normal, sin depender del programa.

Para un archivo completo, el modo Biblioteca procesa una carpeta entera y da el estado de cada documento — correcto, parcial o fallido — para revisar solo lo que de verdad necesita atención en vez de repasar documento por documento.

// detalle técnico

Cada documento se procesa página a página: primero se comprueba si ya tiene una capa de texto digital (PDF nativo); si no, se aplica reconocimiento óptico con un modelo de visión-lenguaje (Transformers), no un OCR clásico basado solo en patrones de píxeles — lo que ayuda con letra manuscrita o escaneos de peor calidad.

El modo «Base» sacrifica velocidad por precisión para esos casos difíciles. La salida se guarda en dos formatos independientes por documento: un .md con el texto extraído (pensado para alimentar después un índice de búsqueda) y un PDF idéntico visualmente al original pero con una capa de texto invisible superpuesta — el escaneo en sí nunca se modifica.

// ejemplo concreto

Un lote de 50 expedientes escaneados de una gestoría: el proceso por lotes los digitaliza uno a uno, marcando cada documento como correcto, parcial (algunas páginas sí, otras no — típico en documentos con sellos o manuscritos encima del texto) o fallido. Es habitual que 2-3 de esos 50 salgan como «parcial» por mala calidad de escaneo; no es señal de que algo esté mal, es la realidad de digitalizar papel antiguo.

// cómo empezamos


Necesito uno o varios documentos de muestra (PDF escaneado o foto) representativos de tu archivo, para probar el resultado real antes de comprometerte a nada. Si el archivo es grande, se hace primero una prueba de alcance reducido sobre una carpeta pequeña.

Recibes el texto extraído y el PDF con capa de búsqueda de cada documento; los originales en papel, si me los facilitas físicamente, se devuelven en el mismo estado en que llegaron.


// cómo se ve en uso




1. Punto de partida — un PDF escaneado, sin texto digital.



2. Procesamiento — cada página se analiza y digitaliza en local.



3. Resultado — el texto queda buscable y verificable página a página.



4. Exportación — el documento final se exporta ya listo para usar.

// servicios que puedo ofrecer con esto

- **Digitalización de archivo histórico o administrativo** — actas, expedientes, escrituras — con entrega tanto del texto extraído como del PDF original con capa de búsqueda añadida, sin alterar el escaneo.
- **Migración puntual de papel a formato digital** para despachos, gestorías y notarías, con un informe de qué documentos han quedado perfectos y cuáles necesitan revisión manual.
- **Primer paso de un flujo mayor de consulta documental:** el texto extraído puede alimentar directamente un asistente de búsqueda en lenguaje natural (ver el manual de RagDesk).