

// juan manuel neupavert alzola

Digitalización documental (escáner + OCR local)

Del papel (o del PDF escaneado sin texto) a un archivo buscable, clasificado y con control de calidad — sin que los documentos salgan del equipo

servicio activo

Escáner cenital CZUR · programa propio de digitalización · reconocimiento de texto 100% local · entrega en Markdown + PDF buscable

// el problema

Un archivo en papel, o una carpeta llena de PDF que en realidad son fotos de páginas, no se puede buscar, ni indexar, ni citar. Para encontrar un dato hay que abrir documento por documento. Cuando el volumen crece — cientos de expedientes, actas o contratos — eso deja de ser viable.

La salida rápida sería subirlo todo a un servicio de OCR en la nube. Pero eso significa mandar documentación sensible a un tercero solo para convertirla, y en muchos casos (datos personales, expedientes, historiales) eso ni siquiera es una opción legalmente cómoda.

Y hay un problema de fondo con el OCR automático: cuando el sistema no está seguro de lo que ha leído, la tentación es rellenar el hueco con una suposición. Un error silencioso en un documento que después alguien va a dar por bueno es peor que un hueco marcado como tal.

// qué hace

Digitalizo tu archivo con un **escáner cenital CZUR** — la cámara va por encima, así que no hay que encuadrar libros ni forzar el lomo, y el ritmo de captura es de segundos por página. Sobre las imágenes resultantes corre un **programa propio de reconocimiento de texto que funciona enteramente en local**, en mi equipo, sin conexión a ningún servicio externo.

Antes de entregarte nada, el texto pasa por **tres pasadas de corrección**, de la más automática a la más manual:

1. **Limpieza determinista.** Reglas que eliminan los artefactos típicos del OCR: guiones de final de línea que parten palabras, saltos de línea sobrantes, cabeceras y pies de página repetidos en cada hoja, espaciado irregular.
2. **Corrector ortográfico con diccionario local.** Sobre el texto ya limpio, marca las palabras improbables y propone corrección — a nivel de palabra, sin reinterpretar el sentido. El diccionario se amplía con la terminología propia de tu dominio para que no marque como error lo que es vocabulario técnico.
3. **Revisión humana página a página.** Reviso el texto reconocido con la imagen de la página al lado, corrijo lo que haga falta y marco cada página como revisada. Los fragmentos que la máquina no ha podido leer con confianza se dejan señalados explícitamente, nunca inventados.

El entregable por cada documento son **dos archivos**: el texto en formato Markdown (pensado para buscar, indexar o alimentar después un asistente de consulta) y un **PDF buscable** — tu escaneo, visualmente intacto, con una capa de texto invisible superpuesta, de modo que se puede buscar y seleccionar texto en cualquier lector de PDF normal.

// cómo se trabaja un archivo entero

Para una carpeta grande, cada documento se procesa por separado y queda con un estado claro: **correcto** (todas las páginas reconocidas y revisadas), **parcial** (algunas páginas sí, otras marcadas para revisar — típico en documentos con sellos, firmas o anotaciones manuscritas sobre el texto) o **fallido** (calidad de escaneo insuficiente, se avisa antes de seguir).

Eso te permite concentrar la revisión en lo que de verdad la necesita, en vez de repasar documento por documento a ciegas. En un lote real es normal que un pequeño porcentaje salga como «parcial»: no es señal de que algo esté mal, es la realidad de digitalizar papel antiguo o con mucha intervención manual encima.

// dónde viven tus documentos

Todo el proceso ocurre en un equipo con el disco cifrado, en una carpeta exclusiva para tu organización, sin mezclarse con material de ningún otro cliente. Los documentos no se envían a servicios de inteligencia artificial en la nube salvo que lo autorices por escrito para una tarea concreta.

Cumplido el plazo de conservación que acordemos, tus datos se eliminan de forma segura y recibes un certificado de qué se ha borrado y cuándo. Si me facilitas originales en papel, se devuelven en el mismo estado en que llegaron.

// un caso concreto

Una gestoría con unos 50 expedientes en papel, cada uno de entre 10 y 40 páginas, mezcla de impresos, formularios rellenos a mano y correspondencia. Se capturan con el CZUR en una tarde, el reconocimiento y la limpieza corren en local durante la noche, y la revisión se centra en las ~8 páginas que el sistema ha marcado como dudosas (casi todas por firmas o sellos encima del texto).

El resultado es una carpeta con los 50 expedientes en texto buscable y en PDF con capa de búsqueda, más un pequeño informe de qué documentos quedaron perfectos y cuáles conviene que alguien de la gestoría revise una segunda vez.

// cómo empezamos

Necesito **uno o varios documentos de muestra** representativos de tu archivo (una foto o un PDF escaneado bastan) para hacerte una prueba real y que veas el resultado antes de comprometerte a nada.

Si el archivo es grande, empezamos con una **prueba de alcance reducido** sobre una carpeta pequeña; a partir de ahí cerramos por escrito qué se entrega, en qué plazo y a qué precio sobre un alcance definido.

// cómo se ve en uso

CAPTURA PENDIENTE

Captura con el escáner CZUR

El escáner cenital en funcionamiento sobre un documento encuadernado, mostrando que no hace falta forzar el lomo.

CAPTURA PENDIENTE

Punto de partida vs. resultado

Un PDF escaneado sin capa de texto al lado del mismo documento ya buscable, para ver el antes y el después.

CAPTURA PENDIENTE

Revisión página a página

Pantalla de revisión con el texto reconocido a la izquierda y la imagen de la página a la derecha, y el botón de «marcar como revisada».

CAPTURA PENDIENTE

Estado de un lote

Lista de documentos de una carpeta con su estado (correcto / parcial / fallido) y el número de páginas pendientes de revisar.

CAPTURA PENDIENTE

Fragmento marcado como ilegible

Detalle del texto donde un fragmento que la máquina no pudo leer con confianza aparece señalado en vez de rellenado con una suposición.

CAPTURA PENDIENTE

Entrega final

La carpeta de entrega con, por cada documento, su archivo Markdown y su PDF buscable.

// preguntas frecuentes

¿Hay que desencuadernar los libros o expedientes cosidos?

No. El escáner es cenital (la cámara va por encima), así que se digitaliza con el documento abierto, sin desmontarlo ni dañarlo.

¿Reconoce texto manuscrito?

Depende de la letra y de la calidad. El texto mecanografiado o impreso se reconoce bien; el manuscrito, según el caso — y lo que no se pueda leer con confianza se marca como dudoso, no se inventa.

¿Necesita conexión a internet?

No. Tanto la captura como el reconocimiento de texto funcionan enteramente en local.

¿Qué pasa con los originales en papel?

Si me los facilitas físicamente, se devuelven en el mismo estado en que llegaron. También puedo trabajar solo con escaneos que me envíes tú por un canal seguro.

¿Esto sirve para montar después un buscador o un asistente de consulta?

Sí — el texto en Markdown está pensado precisamente para eso. Es el primer paso natural antes de un sistema de consulta documental en lenguaje natural (ver el manual de RagDesk).

// servicios que puedo ofrecer con esto

- **Digitalización de archivo histórico o administrativo** — actas, expedientes, escrituras, correspondencia — con entrega del texto extraído y del PDF original con capa de búsqueda añadida, sin alterar el escaneo.
- **Migración puntual de papel a formato digital** para gestorías, despachos y notarías, con un informe de qué documentos han quedado perfectos y cuáles necesitan una segunda revisión.
- **Preparación del archivo para un sistema de consulta:** el texto extraído alimenta directamente un asistente de búsqueda en lenguaje natural o un índice documental.