

// juan manuel neupavert alzola

RagDesk (Asistente documental privado)

Responde preguntas en lenguaje natural sobre una colección de documentos, citando siempre la página exacta de origen — y diciendo «no lo sé» cuando la respuesta no está en el material

demo pública en vivo

FastAPI · LlamaIndex · ChromaDB · embeddings multilingües en proceso · Ollama / OpenAI / Anthropic · app de escritorio (Tauri) o despliegue web multi-inquilino

// el problema

Buscar por palabra clave en cientos o miles de páginas falla en cuanto la respuesta está formulada de otra manera: si el documento dice «prórroga tácita» y tú buscas «renovación automática», no aparece. Y aunque aparezca, sigues teniendo que abrir cada resultado y leerlo.

Un asistente genérico como ChatGPT o Claude responde con fluidez, pero mezcla lo que hay en tus documentos con su conocimiento general — y no puedes distinguir una cosa de la otra. Cuando la respuesta importa (un contrato, una norma, un expediente), confiar a ciegas no es aceptable.

Y para muchas organizaciones, subir toda su documentación a un servicio de terceros para poder consultarla no es una opción.

// qué hace

RagDesk indexa una colección de documentos — los que salen del proceso de digitalización, o cualquier PDF, Word, Markdown o texto ya digital — y responde preguntas sobre ellos en lenguaje natural. Cada respuesta viene con sus **fuentes**: el archivo y la página exactos de donde ha salido cada dato.

Cuando el documento tiene su PDF buscable emparejado, la cita no es solo «página 14»: al desplegarla, RagDesk **abre el PDF dentro de la propia aplicación, salta a esa página y dibuja un recuadro sobre el párrafo exacto**. Verificar una respuesta pasa de ser un acto de fe a un vistazo de tres segundos. Es una capa visual al mostrarlo; el archivo original nunca se modifica.

Tiene una **salvaguarda contra respuestas inventadas**: si ningún fragmento del corpus supera un umbral de relevancia, al modelo se le dice explícitamente que no hay contexto, y el asistente responde que la información no está en los documentos — en vez de contestar de memoria.

Puede funcionar **enteramente en el equipo del cliente** (modelo de lenguaje local con Ollama, base de vectores local, embeddings en proceso), sin que ningún documento salga de la máquina; o usar un modelo en la nube (Anthropic, OpenAI) como alternativa configurable cuando conviene por coste o velocidad, manteniendo aun así los documentos y su índice en local.

Se entrega de dos formas, según lo que encaje con tu equipo: como **aplicación de escritorio de solo consulta** (una ventana nativa — preguntar, ver la cita, abrir el documento — sin ninguna opción de subir o borrar por error), o como **acceso web** a un servicio alojado y multi-inquilino, para clientes sin hardware potente que solo quieren entrar por el navegador.

// cómo funciona por dentro

Cada documento se divide en fragmentos de tamaño ajustable, con solapamiento entre fragmentos para no perder contexto en los cortes, y se convierten en **vectores semánticos** (embeddings) guardados en una base

vectorial local. Al llegar una pregunta, se recuperan primero los fragmentos más parecidos *por significado* — no por coincidencia de palabras — y se le pasan al modelo de lenguaje para que redacte la respuesta citando de dónde salió cada dato.

El modelo de embeddings por defecto es multilingüe (`paraphrase-multilingual-MiniLM`); el umbral de relevancia que activa el «no lo sé» está calibrado para ese modelo y se recalibra si se cambia. En el despliegue web hay además un **reranker** que reordena los fragmentos recuperados con un modelo más fino — mejora mucho las preguntas por un término concreto.

El modelo de lenguaje es intercambiable sin tocar el resto: local (Ollama) o en la nube (Anthropic, OpenAI). Una regla de *grounding* fija —responder solo desde el contexto, nunca citar una fuente que no esté presente, admitir cuando algo no está— se añade a cada consulta y no la puede debilitar la configuración de cada cliente.

// caché de preguntas verificadas

Para no volver a pagar una llamada al modelo por una pregunta que ya se respondió, RagDesk guarda pares de pregunta y respuesta verificados y los reutiliza cuando llega una pregunta **semánticamente parecida**.

Antes de llamar al modelo, compara la pregunta con las guardadas. Si encuentra una muy cercana, **no responde directamente**: sugiere la respuesta guardada y pregunta «¿te refieres a esto?». Si dices que sí, la respuesta llega al instante y sin coste; si dices que no, se responde con normalidad. Esa confirmación es lo que hace segura la caché — equivocarse solo cuesta un «no».

Hay un panel de revisión donde un especialista puede aprobar, rechazar o **editar** una respuesta guardada antes de darle validez. Para un cliente con expertos internos, se puede configurar que nada se sirva hasta que alguien lo apruebe.

// el despliegue web, en detalle

La versión alojada sirve a varios clientes desde un solo servicio. Cada cliente tiene sus propios usuarios y uno o más **RAGs** (cada RAG = un corpus consultable, con su propia «persona» y configuración). El aislamiento entre clientes está verificado: un usuario solo accede a los recursos de su organización.

Tres niveles de acceso: **administrador general** (crea clientes, crea RAGs, sube los documentos), **administrador de cliente** (gestiona los usuarios de su organización) y **miembro** (solo hace preguntas). Subir y borrar documentos es siempre competencia del administrador general.

Puedes probar este modo en vivo en **ragdesk.neupavert.com**.

// un caso concreto

Un despacho con 300 contratos de arrendamiento ya digitalizados. En vez de buscar «cláusula de renovación» y revisar a mano cada resultado, se pregunta directamente: «¿qué contratos tienen renovación automática por un plazo superior a un año?». La respuesta llega con la lista de contratos y la página exacta de cada cláusula citada, cada una a un clic de verse resaltada en su PDF.

// cómo empezamos

Se hace una **prueba de alcance reducido** sobre unos pocos documentos tuyos — con 2 a 5 basta — para que veas el resultado real antes de decidir si conviene ampliarlo a todo el archivo.

Ahí decidimos dos cosas: si el modelo de lenguaje va **en local** (nada sale del equipo, necesita una máquina con algo de potencia) o **en la nube** (más rápido y barato de arrancar, con los documentos aun así en local); y

si la entrega es la **app de escritorio** o el **acceso web**.

Hace falta que el archivo esté ya digitalizado; si no lo está, se combina primero con el servicio de digitalización.

// cómo se ve en uso



CAPTURA PENDIENTE

Recuadro sobre el párrafo citado en el PDF

El visor de PDF integrado abierto en la página citada, con un recuadro dibujado sobre el párrafo exacto del que sale la respuesta.

CAPTURA PENDIENTE

Respuesta «no lo sé»

El asistente respondiendo que la información no está en los documentos, en vez de improvisar una respuesta.

CAPTURA PENDIENTE

Confirmación de la caché

El aviso «ya hay una respuesta guardada para una pregunta parecida: ...» con los botones Sí / No.

CAPTURA PENDIENTE

Consola del despliegue web

La vista de administrador general de ragdesk.neupavert.com: lista de clientes, y por cliente sus usuarios y sus RAGs.

// preguntas frecuentes

¿Puedo tener varios clientes con archivos distintos?

En la app de escritorio, cada instalación tiene un único índice: para clientes distintos, instalaciones separadas. El despliegue web sí es multi-inquilino de serie.

¿Necesita internet?

En la versión local, solo la primera vez, para descargar los modelos. Después funciona sin conexión. En la versión web, se entra por el navegador.

¿Se puede inventar una respuesta igualmente?

El diseño lo evita con el umbral de relevancia, la regla de grounding y la cita obligatoria. Con un modelo local pequeño todavía puede fallar en algún caso; para producción se recomienda un modelo en la nube, que es mucho más fiable siguiendo esas reglas.

¿Mis documentos salen del equipo?

En la versión local, no: ni los documentos ni el índice. Si se usa un modelo de lenguaje en la nube, solo viaja el fragmento de texto necesario para responder cada pregunta, nunca el archivo entero — y aun así es opcional.

¿Qué formatos admite?

PDF, Word (.docx), Markdown y texto plano. Los PDF que vienen del proceso de digitalización llevan además la información de posición que permite el recuadro sobre el párrafo citado.

// servicios que puedo ofrecer con esto

- **Asistente de consulta interna** para despachos, gestorías y empresas sobre su propia normativa, contratos, manuales o expedientes — con cita a página verificable.
- **Prueba de alcance reducido** sobre unos pocos documentos tuyos, antes de decidir si conviene ampliarlo a todo el archivo.
- **Elección de despliegue:** 100% local en tu equipo, o acceso web alojado para equipos sin hardware potente.
- **Mantenimiento y ampliación mensual** conforme se añaden documentos nuevos a la colección, con revisión periódica de la caché de respuestas.